



Instituto Brasileiro de Geografia e Estatística
Escola Nacional de Ciências Estatísticas
Bacharelado em Estatística



RELATÓRIO PIBIC 2022-2023

MÚSICA NO R: REVISÃO SISTEMÁTICA E APLICAÇÃO

LUCAS UCHOA MOREIRA GOMES

Rio de Janeiro

LUCAS UCHOA MOREIRA GOMES

RELATÓRIO PIBIC 2022-2023
MÚSICA NO R: REVISÃO SISTEMÁTICA E APLICAÇÃO

Orientadora: ALINNE DE CARVALHO VEIGA

Coorientador: GUILHERME DOS SANTOS

Rio de Janeiro

2023

Resumo

Este relatório apresenta uma investigação sobre a análise de dados musicais no contexto brasileiro, destacando a crescente importância da análise estatística de dados relacionados à música na era digital. O projeto foi dividido em duas etapas: uma revisão sistemática e uma análise de gêneros musicais com base em cifras musicais.

Na primeira fase, realizou-se uma revisão bibliográfica, visando identificar e discutir documentos acadêmicos relevantes sobre análise de dados musicais. Além disso, buscou-se mapear os principais pacotes disponíveis na linguagem de programação R para análise musical.

A segunda etapa concentrou-se na aplicação prática dos conhecimentos adquiridos durante a revisão sistemática. Nesta fase, foram exploradas diversas áreas de aplicação, com foco na análise de gêneros musicais usando cifras musicais como principal fonte de dados. Foram selecionados 15 gêneros populares e coletadas informações das 100 músicas mais acessadas em cada gênero, resultando em uma base de dados com 1500 composições.

O processamento dos dados envolveu a extração e padronização de acordes e metadados musicais com o uso do pacote `chorrrds` (WUNDERVALD e HULTMANN FILHO, 2018). Para garantir a comparabilidade entre as composições, uma função foi desenvolvida para transpor todas as músicas para o tom de C (Dó maior). Em seguida, adotou-se o método TF-IDF (*Term Frequency - Inverse Document Frequency*) para avaliar a importância relativa das progressões musicais em cada gênero, permitindo a identificação de características musicais notáveis.

Os resultados revelaram diferenças marcantes entre os gêneros musicais analisados, destacando, por exemplo, a riqueza harmônica da bossa nova e tendências a acordes maiores em gêneros como sertanejo e rock.

Este é um estudo inicial na exploração da análise de dados musicais, oferecendo informações valiosas para futuras pesquisas e aplicações relacionadas à música, utilizando a linguagem R.

Palavras-Chave: Dados musicais; Revisão sistemática; Programação; R; Cifras musicais.

1 Introdução

A música é uma forma de expressão cultural muito presente na história da humanidade, manifestando-se de maneira diversificada ao longo do tempo e em diferentes cenários. Seu estudo é multifacetado, podendo ser realizado de diversas perspectivas.

Nas últimas décadas, com o crescimento da mídia digital, houve uma explosão na quantidade de dados musicais disponíveis para população, que abrangem informações sobre composição, gravação, desempenho e preferências do público (LI, 2012). Esses ricos conjuntos de informações oferecem oportunidade de exploração em todas suas dimensões, desde a análise de padrões musicais até a compreensão das tendências de mercado e influências culturais.

A análise estatística de dados musicais tem se mostrado uma área de pesquisa crescente, impulsionada pelo acesso a grandes volumes de dados musicais digitais e pelo desenvolvimento contínuo de técnicas avançadas de análise de dados (WEIHS, 2016). Neste relatório, explora-se a interessante interseção entre música e análise de dados, examinando os tipos de dados musicais disponíveis, bem como as ferramentas e técnicas utilizadas para sua análise.

1.1 Dados musicais

Dados musicais são informações relacionadas à música que podem ser armazenadas e processadas de forma estruturada. Podem incluir uma ampla variedade de elementos que compõem uma música, como notas, acordes, ritmos, letras, durações, instrumentos, gêneros, artistas, álbuns, entre outros.

As notas musicais são representações gráficas e sonoras destinadas a expressar as variações da altura do som na música. A partir dessas notas, são formados os acordes, que representam a combinação simultânea de três ou mais notas musicais, de acordo com algumas regras específicas.

Por exemplo, uma tríade maior, que é um acorde composto por três notas, inclui uma nota fundamental, a terça maior (quatro semitons acima da nota fundamental) e a quinta justa (três semitons acima da terça maior).




Figura 1: Representação de notas musicais em uma partitura. O símbolo a esquerda é uma clave de Sol. Abaixo estão os nomes das notas, tanto no formato de cifra, quanto o nome em si.

E7M G#m7
And your skin
F#6(11)
Oh, yeah, your skin and bones
E7M G#m7 F#6(11)
Turn into something beautiful
E7M G#m7
Do you know
F#6(11) E7M
For you, I'd bleed myself dry?
B
For you, I bleed myself dry
(F#6(11) E7M B)

2




Figura 4: Visualização de um espectrograma. É uma representação visual de um sinal sonoro, contendo informações de amplitude (intensidade do som), tempo e frequência.

Existem três tipos principais de dados musicais:

1. **Dados simbólicos:** Essa categoria inclui representações musicais que codificam elementos usando notação musical, como partituras (ver Figura 1), cifras (ver Figura 2), arquivos MIDI (*Musical Instrument Digital Interface* ver Figura 3), tablaturas e formatos de arquivo similares. Os dados simbólicos descrevem informações como notas, acordes, durações e estrutura musical.
2. **Dados de áudio:** São dados digitais que representam o som da música, geralmente armazenados em formatos de arquivo de áudio, como MP3, WAV ou FLAC. Além disso, podem ser representados em formato de imagem, como espectrogramas (ver Figura 4). Os dados de áudio capturam a gravação ou a performance real da música, incluindo elementos sonoros como timbre, melodia, ritmo e harmonia.
3. **Metadados:** Esses dados contêm informações adicionais sobre a música, como o nome do artista, álbum, gênero, data de lançamento e licença de direitos autorais. Os metadados desempenham um papel fundamental na organização, pesquisa e análise de dados musicais.

1.2 Análise de dados musicais no R

A análise de dados musicais envolve a aplicação de técnicas computacionais, estatísticas e algoritmos para extrair informações úteis e significativas desses dados. Isso pode incluir a identificação de padrões musicais, análise de sentimentos, classificação de gêneros ou de compositores, recomendação de músicas, entre outras aplicações.

O R é uma linguagem de programação popular e um ambiente de análise estatística que oferece diversas bibliotecas e pacotes. Alguns são projetados para trabalhar especificamente com dados musicais, como por exemplo, `tuneR`, `music21`, `Rspotify`, `chorrrds` e `pyramidi`.

2 Objetivos

Este projeto foi dividido em duas etapas. A primeira fase, que se estendeu por aproximadamente três meses, consistiu em realizar uma revisão sistemática da literatura, com o objetivo de selecionar, analisar e discutir documentos acadêmicos relevantes sobre o tema.

A segunda etapa, que durou cerca de oito meses, foi dedicada à aplicação prática dos conhecimentos adquiridos durante a revisão sistemática. Foram exploradas diversas áreas de aplicação e, por fim, o estudo realizado foi uma análise de gêneros musicais, utilizando cifras como elemento central.

3 Revisão sistemática

3.1 *Music Information Retrieval*

Durante toda a etapa de pesquisa bibliográfica, o conceito de *Music Information Retrieval* (MIR) apareceu com frequência, devido à sua relevância e compatibilidade com o escopo deste estudo.

MIR é uma área de pesquisa interdisciplinar que combina música, ciência da computação e processamento de sinais de áudio para extrair informações significativas de arquivos de música (TYPKE et al., 2005). Seu objetivo central é desenvolver algoritmos e técnicas que permitam a organização, recuperação, exploração e análise de grandes coleções de dados musicais. No âmbito de MIR, uma ampla gama de tarefas e desafios são enfrentados pelos pesquisadores, cada um com o propósito de desvendar aspectos distintos da música.

Um dos principais artigos encontrados sobre esse assunto na pesquisa foi “*Music Information Retrieval*” de J. Stephen Downie. Neste trabalho, o autor destaca que MIR é um esforço de pesquisa que visa desenvolver esquemas inovadores de busca baseada em conteúdo, criar interfaces novas e estabelecer mecanismos de entrega em rede, tudo com o objetivo de tornar o acervo mundial de música acessível a todos (DOWNIE, 2003).

Essas são algumas aplicações de estudos das técnicas de *Music Information Retrieval*:

1. **Transcrição automática:** Envolve a extração de informações simbólicas, como notas musicais ou acordes, a partir de gravações de áudio. Esse processo permite transformar música em notação musical compreensível por máquinas, o que tem implicações significativas para a análise de peças musicais complexas, a criação de partituras e até a geração automática de música.
2. **Análise de acordes:** Envolve identificar os acordes individuais ou progressões de acordes presentes em uma composição musical.
3. **Deteção de ritmo e batida:** Trata-se de identificar e estimar a estrutura rítmica de uma música, incluindo a deteção de batida e o andamento musical.
4. **Recomendação musical:** Envolve criar sistemas inteligentes capazes de recomendar músicas com base nas preferências e características do usuário.

3.2 *Hidden Markov Models*

Hidden Markov Models (HMMs) são modelos estatísticos amplamente utilizados para representar sistemas dinâmicos nos quais as observações são parcialmente influenciadas por estados ocultos não diretamente observáveis. Esses modelos podem ser aplicados em uma variedade de campos, incluindo processamento de fala, reconhecimento de padrões, bioinformática e também na análise de sequências musicais.

Pode-se encontrar um exemplo de aplicação de HMM na análise de dados musicais no trabalho de (RAPHAEL, 2003). Nesse estudo, os pesquisadores empregaram modelos ocultos de Markov para explorar aspectos harmônicos da música, utilizando notas e ritmo como elementos fundamentais. A premissa é que a tônica de um acorde em um determinado período de tempo possui uma alta probabilidade de ser a mesma que em um período anterior. O modelo de HMM adotado nesse contexto considera que, sempre que um estado específico é alcançado, novos dados são gerados a partir de uma distribuição associada a esse rótulo harmônico.

Em outro artigo, (LÓPEZ, 2019), é apresentado um novo algoritmo de identificação de tonalidade musical baseado em HMM. Esse algoritmo tem a capacidade de identificar a tonalidade local e global em músicas tanto em formato simbólico quanto em áudio. O estudo descreve os detalhes do algoritmo, incluindo seus parâmetros configuráveis, como as distribuições de probabilidade de transição e emissão. Além disso, são discutidas as capacidades de identificação de tonalidade local, ilustrando com um exemplo da obra de Chopin. O artigo também avalia o desempenho global do modelo, comparando-o com diferentes perfis tonais. Conclui-se que um método de conjunto, que utiliza previsões de diversos perfis tonais, alcança um desempenho melhor para tonalidades maiores e no geral, mas ainda não supera o estado da arte para tonalidades menores.

3.3 *Classificação de gêneros musicais*

Melodias monofônicas são melodias musicais em que apenas uma única linha melódica é tocada ou cantada, sem acompanhamento de acordes simultâneos.

O estudo (VERCOE, 2015) descreve o uso de HMM para classificar músicas folk de diferentes países com base em suas melodias monofônicas. Diversas representações e estruturas de HMM foram avaliadas, revelando que as melodias da música folk de distintos países exibem características estatísticas únicas. Os resultados sugerem que essa abordagem pode ser aplicada a outras tarefas de classificação musical e sinais musicais. No entanto, a melodia sozinha não é suficiente para a classificação musical, sendo necessário considerar outras características como harmonia, instrumentação e estilo de performance para melhoria do desempenho.

Outro artigo, (DALIN-VOLSING, 2017), aborda a classificação dos gêneros Pop, Jazz, Clássico e R&B, também utilizando HMM. Os resultados mostram uma precisão máxima de 0,742 para dados de áudio e 0,540 para dados simbólicos e indicam que a combinação de ambos os métodos não melhora a precisão.

3.4 Progressão de acordes

O estudo (PAIEMENT, 2005) aborda a modelagem de progressões de acordes na música tonal, destacando a importância dessas sequências de acordes na música. O artigo propõe uma representação para acordes que leva em conta dissimilaridades psico-acústicas, usando probabilidades estimadas de substituições de acordes para introduzir suavização em modelos gráficos que observam essas progressões. Os parâmetros dos modelos gráficos são aprendidos com o algoritmo EM, e o algoritmo da Árvore de Junções é usado para inferência. A pesquisa conclui que as progressões de acordes têm dependências globais que podem ser capturadas melhor com uma estrutura de árvore relacionada ao compasso do que com um modelo HMM dinâmico simples que se concentra em dependências locais. A pesquisa também sugere que esses modelos podem ser úteis em tarefas de transcrição musical, recuperação de informações musicais, reconhecimento de gênero musical e análise musical.

O artigo de (FERREIRA, 2021) explora a previsibilidade na música brasileira, analisando sequências de acordes em oito gêneros musicais diferentes. Os resultados indicaram que Reggae e Pop parecem ser os menos aleatórios em termos de progressões de acordes. Além disso, ao aplicar a mesma análise a séries de músicas organizadas aleatoriamente, os resultados mostraram a aleatoriedade dessas séries reorganizadas, evidenciando a robustez da abordagem utilizada.

4 Aplicação

A segunda parte do projeto foi a aplicação de conhecimentos adquiridos na revisão sistemática.

A primeira ideia foi trabalhar com música de concerto (também conhecida como música clássica), considerando o uso de espectrogramas ou arquivos MIDI em combinação com *Hidden Markov Models*. O objetivo principal seria desenvolver um algoritmo capaz de classificar composições musicais com base em seus respectivos compositores.

Logo no início dessa etapa, foi descartada a possibilidade de usar espectrogramas, devido à sua limitada interpretabilidade musical, o que não estava alinhado com os objetivos deste projeto. Assim, decidiu-se prosseguir utilizando arquivos MIDI como fonte de dados.

Foi utilizada uma base de dados composta por 295 arquivos MIDI, de 19 autores de música clássica. Para o processamento desses arquivos, utilizou-se diferentes pacotes no R, como *pyramidi*, *tuneR*, *tabR* e *gm*.

Diversos desafios apareceram durante essa fase. A complexidade da leitura de arquivos MIDI se mostrou problemática, com a maioria das composições sendo importadas de forma inadequada e apresentando erros, como a exclusão de pausas musicais.

Além disso, constatou-se limitações significativas nos pacotes disponíveis no R para a manipulação de arquivos MIDI. Todos os quatro pacotes testados (*pyramidi*, *tuneR*, *tabR* e *gm*) dependiam de softwares musicais externos, como MuseScore¹ e LilyPond², para o

¹<https://musescore.org/pt-br>

²<https://lilypond.org/>

correto manuseio dos dados. Infelizmente, essa integração frequentemente apresentava falhas, evidenciando a necessidade de avanços substanciais para viabilizar uma análise abrangente de dados musicais por meio de arquivos MIDI no R.

Apesar dos esforços consideráveis na exploração de documentação de pacotes e revisão de artigos relacionados, não foram encontradas soluções gratuitas que permitissem ou facilitassem o estudo com arquivos MIDI. Dessa forma, decidiu-se seguir por uma abordagem alternativa, utilizando dados de cifras musicais.

Na música popular, é frequente o uso de cifras musicais, que priorizam a componente harmônica da música, pressupondo que o músico já tenha conhecimento da melodia e do ritmo. Essa nova abordagem se mostrou mais viável e é a aplicação que será detalhada nas próximas seções deste relatório.

O objetivo foi realizar uma análise de dados, buscando identificar características musicais notáveis nos gêneros musicais mais populares do Brasil, organizando-os de acordo com suas afinidades musicais.

5 Metodologia

5.1 Web scraping

Para aplicação, foram utilizadas cifras musicais disponíveis no site Cifra Club³, que é a maior plataforma dessa área do país. O escopo do estudo abrangeu 15 gêneros musicais populares, para os quais foram coletadas informações das 100 músicas mais acessadas na plataforma em cada gênero. Essa coleta de dados foi realizada por meio de técnicas de *web scraping*, utilizando o pacote *rvest* (WICKHAM, 2016). O resultado desse procedimento foi a obtenção de uma base de dados contendo 1500 composições musicais.

5.2 Gêneros musicais

Gêneros musicais funcionam como categorias que abrangem composições musicais que compartilham elementos em comum. Estes elementos podem ser função, estrutura, contexto cultural, instrumentação, mídia utilizada e outros (WUNDERVALD e HULTMANN FILHO, 2018). Pode-se dizer que cada estilo musical possui uma espécie de assinatura harmônica característica que o identifica, mas também podem existir variações e desvios dessa norma.

Neste estudo, optou-se por explorar os gêneros musicais mais acessados no site Cifra Club. Os gêneros selecionados foram: Axé, Bossa Nova, Blues, Forró, Funk, Gospel, Jazz, K-Pop, MPB, Música Alternativa, Rock, Samba, Sertanejo, Pagode e Pop.

³<https://www.cifraclub.com.br/>

5.3 Processamento de dados

O processamento dos dados foi conduzido utilizando o pacote `chordrds`, que permitiu a extração e padronização dos acordes e metadados musicais.

Nessa etapa, alguns problemas foram encontrados, como erro de notação de cifra, pois o mesmo acorde musical pode ser representado de formas diferentes, como A# (Lá sustenido) e Bb (Si bemol). Para assegurar a uniformidade, realizada uma substituição de todos os acordes com bemol para notação do seu acorde equivalente com sustenido.

5.4 Desenvolvimento e aprimoramento de funções

5.4.1 `get_chords`

Em músicas populares, é comum o uso de capotraste no violão para facilitar a execução de acordes. Dessa forma, a pessoa executa a forma de um acorde, porém o som que sai do instrumento é de outro. A Figura 5 mostra um exemplo de uma música que o tom original é Fm (Fá menor), porém a forma dos acordes é executada no tom de Em (Mi menor).

Céu Azul

Charlie Brown Jr.

Cifra: Principal (violão e guitarra) ▾

♥ Favoritar Cifra

Tom: **Fm** (forma dos acordes no tom de Em)

Capotraste na 1ª casa

[Intro] **Em7(9)** **D** **Bm** **A11**

[Dedilhado - Intro]

Parte 1 de 2

Em7(9) **D**

```
E|-----|
B|-----|
G|---12---12-----12-----12-12-----|
D|---13---13-----13-----13-13-----|
A|-----|
E|--0---0---0---11---11-11-----0-----|
  ↓ ↑ ↓ ↑ ↓      ↓ ↑ ↓ ↓ ↑ ↑ ↓
```

Figura 5: Trecho da cifra da música Céu Azul, do Charlie Brown Jr., que utiliza capotraste na primeira casa. Fonte: Cifra Club

Ao analisar as músicas com capotraste na base de dados deste projeto, observou-se uma inconsistência entre a tonalidade indicada nas cifras e a tonalidade real da música. Uma discrepância como essa afetaria significativamente a análise musical deste estudo.

Para solucionar esse problema, foram realizadas melhorias no pacote `chorrrds`, mais especificamente na função `get_chords`, que é responsável por importar as cifras do Cifra Club. Analisou-se a forma que a função funciona para então realizar o aprimoramento, a fim de incorporar a capacidade de identificar informações relacionadas ao uso de capotraste.

5.4.2 `transpose_chords`

A principal contribuição deste projeto ao pacote foi o desenvolvimento da função chamada `transpose_chords`, que permite a conversão do tom de uma música. A criação dessa função foi um desafio significativo devido à diversidade de representações de acordes, que incluem variações como: Em, C7M, A11, F#m7(9), G/B, entre outros.

O processo envolveu a identificação precisa de cada formato de acorde, utilizando expressões regulares (*Regex*). Em seguida, foi calculada a distância harmônica entre o tom original da música e o tom desejado como retorno. E então essa distância foi aplicada a todos os acordes presentes na música, efetivamente transpondo-os para a nova tonalidade de interesse.

5.4.3 `transpose_capo`

Além disso, foi desenvolvida a função `transpose_capo`, que recebe informações das duas funções apresentadas. O objetivo dessa é ajustar a tonalidade dos acordes das músicas que utilizam capotraste, levando em consideração a posição do capotraste indicada nas cifras.

5.4.4 Transposição de tonalidade

Dessa forma, todas as músicas foram transpostas para o mesmo tom. Foi selecionado o tom de C (Dó maior) para músicas com tom maior e, seu acorde relativo menor, Am (Lá menor) para músicas com tom menor, por serem considerados tons neutros. A Figura 6 apresenta um exemplo do resultado final da base de dados, após a execução das funções.

A padronização de todas as músicas para um mesmo tom desempenha um papel fundamental na análise musical por várias razões:

1. **Comparabilidade dos dados:** Ao transpor todas as músicas para o mesmo tom, cria-se uma base de dados padronizada e homogênea. Isso significa que todas as músicas agora compartilham a mesma referência tonal, facilitando comparações diretas entre diferentes gêneros musicais e composições.
2. **Análise no campo harmônico:** O uso do mesmo tom para todas as músicas permite que os pesquisadores explorem aspectos harmônicos com maior precisão. Isso significa que as relações entre os acordes, escalas e progressões musicais são mais facilmente identificáveis, o que enriquece a análise musical.

	chord	key	capo	song	artist	chordC	keyC
113	G	Em	1	Ceu Azul	Charlie Brown Jr	C	Am
114	A9	Em	1	Ceu Azul	Charlie Brown Jr	D9	Am
115	Em	Em	1	Ceu Azul	Charlie Brown Jr	Am	Am
116	Bm11	Em	1	Ceu Azul	Charlie Brown Jr	Em11	Am
117	A9	Em	1	Ceu Azul	Charlie Brown Jr	D9	Am
118	G	Em	1	Ceu Azul	Charlie Brown Jr	C	Am
119	A9	Em	1	Ceu Azul	Charlie Brown Jr	D9	Am
120	Em7(9)	Em	1	Ceu Azul	Charlie Brown Jr	Am7(9)	Am
121	D	Em	1	Ceu Azul	Charlie Brown Jr	G	Am
122	Bm	Em	1	Ceu Azul	Charlie Brown Jr	Em	Am
123	A11	Em	1	Ceu Azul	Charlie Brown Jr	D11	Am
124	Em7(9)	Em	1	Ceu Azul	Charlie Brown Jr	Am7(9)	Am
125	D	Em	1	Ceu Azul	Charlie Brown Jr	G	Am
126	Bm	Em	1	Ceu Azul	Charlie Brown Jr	Em	Am
127	A11	Em	1	Ceu Azul	Charlie Brown Jr	D11	Am

Figura 6: Parte do dataframe final, exibindo os acordes padronizados em C (Dó maior) da música Céu Azul, do Charlie Brown Jr.

- 3. Eliminação de vieses tonais:** Quando as músicas estão em tons diferentes, nuances tonais podem afetar as conclusões da análise. Por exemplo, algumas tonalidades podem ser percebidas como mais alegres ou tristes, o que poderia distorcer a interpretação dos resultados. Ao padronizar para um tom neutro, tais vieses são minimizados.

Em resumo, a padronização das músicas para um único tom foi um passo essencial para garantir a confiabilidade e comparabilidade dos dados em análises musicais.

No mais, o desenvolvimento dessas funções pode beneficiar estudos futuros, tornando os dados prontamente utilizáveis por outros pesquisadores interessados na mesma área. Todas as funções desenvolvidas e aprimoradas neste projeto estão disponíveis no repositório, que pode ser acessado através deste link: <https://linktr.ee/musicantor>

5.5 Progressões musicais

Uma progressão musical, em termos simples, é uma sequência específica de acordes que ocorre em uma composição, geralmente, seguindo uma ordem predefinida. Nos gêneros populares no Brasil, na maioria das vezes, as progressões são compostas por 4 acordes.

Na música, cada acorde pode ter uma função diferente. Por isso, para uma análise musical mais robusta e significativa, optou-se por utilizar as progressões musicais de sequência de quatro acordes como unidade de estudo. A progressão musical desempenha um papel essencial na determinação da harmonia da música.

Segundo (WUNDERVALD e HULTMANN FILHO, 2018), "quando fala-se sobre acordes, deve-se considerar especialmente as progressões deles. Fazer inferência sobre progressões de acordes é essencial para modelar relações de dependência entre acordes."

5.6 Análise de dados

Para esta análise, adotou-se o método TF-IDF (*Term Frequency - Inverse Document Frequency*). Essa técnica é amplamente empregada em processamento de linguagem natural (NLP) e análise textual para avaliar a importância de um termo em relação a um documento dentro de um conjunto de documentos. Neste caso, foi utilizado para o contexto musical.

O cálculo é feito da seguinte forma:

Term Frequency (TF): mede a frequência de um termo em um documento específico.

$$TF_{\text{termo}} = \frac{\text{Número de vezes que o termo aparece no documento}}{\text{Total de termos no documento}}$$

Inverse Document Frequency (IDF): mede a importância relativa de um termo em relação a todo o conjunto de documentos.

$$IDF_{\text{termo}} = \log \left(\frac{\text{Total de documentos}}{\text{Número de documentos que contêm o termo}} \right)$$

TF-IDF: é obtido multiplicando o TF pelo IDF do termo:

$$TF-IDF_{\text{termo}} = TF_{\text{termo}} \times IDF_{\text{termo}}$$

No contexto deste estudo, as progressões musicais são tratadas como palavras em um documento de texto. Assim, na expressão acima, os documentos são os gêneros e os termos são as progressões musicais. Para outras análises, também é possível usar as próprias músicas como documentos.

Essa técnica permite destacar progressões musicais que são frequentes em um gênero específico (alta pontuação de TF) e, ao mesmo tempo, são raras em todo o conjunto de composições (alta pontuação de IDF).

5.7 Limitações do uso de cifras

É importante destacar algumas limitações inerentes ao uso de cifras musicais como base de dados para análise:

1. **Simplificação da representação musical**: Cifras são uma representação simplificada da música, focando principalmente em acordes e progressões harmônicas. Isso pode não capturar nuances importantes, como variações na melodia, ritmo e dinâmica.
2. **Variação na qualidade das cifras**: As plataformas online de cifras funcionam de forma colaborativa, em que o próprio usuário pode enviar informações musicais. Dessa forma, a base de dados de músicas catalogadas cresce de maneira rápida, porém a precisão das cifras disponíveis pode variar significativamente. Algumas cifras podem conter erros ou simplificações que afetam a análise. Para buscar diminuir essa limitação, utilizou-se nesta aplicação as músicas mais acessadas da plataforma, que normalmente possuem as cifras escritas pela equipe técnica do Cifra Club.

3. **Limitação à música popular:** Cifras são mais comuns na música popular, o que limita a aplicabilidade dessa metodologia a gêneros específicos. Para esta aplicação, foram selecionados 15 gêneros populares.

6 Resultados

Os resultados aqui apresentados possuem como data de referência o dia 16/09/2023.

A Figura 7 apresenta a média de acordes distintos por gênero. Notavelmente, o gênero bossa nova se destaca com uma média de 26,5 acordes distintos por música, indicando uma riqueza harmônica em suas composições. Em contrapartida, gêneros como funk e k-pop exibem uma menor variedade harmônica, com médias de 5,8 e 6,5 acordes distintos por música, respectivamente.




Figura 7: Média de acordes distintos por gênero

Os dados da Tabela 1 mostram que gêneros sertanejo (0,77), blues (0,76) e rock (0,73) apresentam uma proporção ligeiramente maior de acordes maiores em suas composições. Isso pode sugerir uma tendência em direção a uma sonoridade mais luminosa e alegre, o que aparenta ser surpreendente para o gênero blues, que é conhecido por ter harmonia mais dramática e triste (WALD, 2010). Por outro lado, gêneros como funk (0,53), bossa nova (0,63), k-pop (0,63), jazz (0,64) e samba (0,65) exibem uma proporção significativamente maior de acordes menores, indicando uma tendência por sonoridades mais melancólicas e emotivas.

A Figura 8 apresenta as três principais progressões musicais com os maiores valores de TF-IDF por gênero. Dentre essas progressões, destacam-se o blues e a bossa nova,

Tabela 1: Proporção de acordes maiores e menores por gênero

	funk	bossa-nova	k-pop	jazz	samba	alternativo	axé	forró	pagode	pop	mpb	gospel	rock	blues	sertanejo
menores	0.47	0.37	0.37	0.36	0.35	0.34	0.33	0.33	0.33	0.33	0.33	0.28	0.27	0.24	0.23
maiores	0.53	0.63	0.63	0.64	0.65	0.66	0.67	0.67	0.67	0.67	0.67	0.72	0.73	0.76	0.77

com valores mais elevados em comparação com os demais gêneros. Essa diferença sugere que essas progressões são particularmente distintivas de seus respectivos gêneros musicais, contribuindo significativamente para a identidade harmônica dessas músicas.

É interessante notar que o gênero funk chama a atenção devido ao fato de suas progressões mais frequentes consistirem na repetição de apenas dois acordes, Dm (Ré menor) e A# (Lá sustenido). Esse padrão rítmico e harmônico característico pode ser uma das principais características do gênero funk, adicionando uma marca única à sua sonoridade.

Essas informações extraídas da análise de TF-IDF ressaltam como as progressões musicais desempenham um papel importante na definição das características distintivas de diferentes gêneros musicais. Essas descobertas podem enriquecer a compreensão da estética musical de cada gênero e fornecer novos conhecimentos valiosos para músicos, compositores e pesquisadores interessados na análise de dados musicais.

7 Conclusão

Neste estudo, foi possível explorar as nuances da análise de dados musicais, focando nos gêneros populares no Brasil.

A revisão sistemática da literatura desempenhou um papel crucial no delineamento deste estudo, fornecendo uma sólida base de conhecimentos e ferramentas necessárias para investigar os dados musicais de forma significativa.

A exploração inicial do uso de arquivos MIDI (*Musical Instrument Digital Interface*) ofereceu valiosas percepções sobre os desafios e oportunidades que essa forma de representação musical oferece. Os obstáculos encontrados ao lidar com esses arquivos, como a complexidade na leitura e as limitações dos pacotes disponíveis, realçaram a necessidade contínua de avanços tecnológicos para análise de dados musicais.

O desenvolvimento e a implementação de funções para a transposição de tonalidades em composições musicais revelou-se uma etapa essencial para a análise. Esse processo de padronização permitiu que todas as músicas fossem avaliadas em um contexto harmônico uniforme, viabilizando uma comparação significativa entre os gêneros. Além disso, são funções que podem contribuir para trabalhos futuros.

Assim, foi possível analisar semelhanças e diferenças entre gêneros populares no Brasil. Bossa nova, samba e pagode se destacam pela quantidade de acordes distintos, indicando uma riqueza harmônica em suas composições. Gêneros como sertanejo, blues e rock apresentam uma proporção maior de acordes maiores em suas composições, sugerindo uma sonoridade mais luminosa e alegre. Os resultados de TF-IDF permitem analisar progressões musicais frequentes em um determinado gênero que não são tão comuns nos demais.



Figura 8: TF-IDF de progressões musicais por gênero

Possíveis trabalhos futuros envolvem classificação de gêneros, análise de sentimentos sobre as progressões musicais mais frequentes, análise temporal sobre as músicas mais acessadas ao longo dos últimos anos e melhoria de eficiência das funções desenvolvidas e aprimoradas.

Por fim, este trabalho contribuiu para a interseção cada vez mais relevante entre música e análise de dados, proporcionando uma visão mais profunda das características musicais que tornam cada gênero único e valioso.

Referências

- CABRAL, G., ZANFORLIN, I., LIMA, R., SANTANA, H. e RAMALHO, G. (2017) Da cifra para o braço: Estudo dos problemas de execução musical em violão e guitarra. *Universidade Federal de Pernambuco*.
- DALIN-VOLSING, S. (2017) Classification of musical genres using hidden markov models.
- DOWNIE, J. S. (2003) Music information retrieval. *Annual Review of Information Science and Technology*.
- FERREIRA, P. QUINTINO, D. W. B. D. A. A. F. C. A. (2021) Is brazilian music getting more predictable? a statistical physics approach for different music genres. *Physica A: Statistical Mechanics and its Applications*.
- LI, T. OGIHARA, M. T. G. (2012) *Music Data Mining*. Chapman Hall/CRC.
- LÓPEZ, N. ARTHUR, C. F. I. (2019) Key-finding based on a hidden markov model and key profiles. *6th International Conference on Digital Libraries for Musicology*.
- PAIEMENT, J. ECK, D. B. S. (2005) A probabilistic model for chord progressions.
- RAPHAEL, C. STODDARD, J. (2003) Harmonic analysis with probabilistic graphical models. *Johns Hopkins University*.
- TYPKE, R., WIERING, F. e VELTKAMP, R. C. (2005) A survey of music information retrieval systems. *Universiteit Utrecht*.
- VERCOE, B. WEI, C. (2015) Folk music classification using hidden markov models.
- WALD, E. (2010) *The Blues: A Very Short Introduction*. Oxford University Press.
- WEIHS, C. JANNACH, D. V. I. R. G. (2016) *Music Data Analysis: Foundations and Applications*. Chapman Hall/CRC.
- WICKHAM, H. (2016) rvest: Easily harvest (scrape) web pages. [s.l.]. *R package version*.
- WUNDERVALD, B. D. e HULTMANN FILHO, R. J. (2018) Engenharia de características baseadas em cifras para a classificação de gêneros na música brasileira. *Trabalho de Conclusão de Curso - Universidade Federal do Paraná*.